

Rapport d'Évaluation

API d'Analyse de Sentiments — SocialMetrics AI

Client : Daunale Treupe

Modèle : Régression logistique (TF-IDF) — scikit-learn
Dataset : 6000 tweets annotés (3000 positifs / 3000 négatifs)


1. Méthodologie

Le modèle repose sur une vectorisation TF-IDF (unigrammes et bigrammes, 5000 features maximum) suivie de deux classifieurs de régression logistique indépendants : l'un prédit la probabilité qu'un tweet soit positif, l'autre qu'il soit négatif. Le score final retourné par l'API est la différence de ces deux probabilités, bornée entre -1 et 1.

Le dataset annoté (6000 tweets, équilibré) a été séparé en un jeu d'entraînement (80 %) et un jeu de validation (20 %, soit 1200 tweets) sur lequel les métriques ci-dessous sont calculées.


2. Matrices de Confusion

2.1 Prédictions positives



Sur 1200 tweets de validation, le modèle identifie correctement 438 tweets positifs et 425 tweets non positifs. Il commet 162 faux positifs et 175 faux négatifs : les erreurs sont réparties de façon assez symétrique, signe que le modèle ne favorise pas excessivement une classe par rapport à l'autre.

2.2 Prédictions négatives



De façon symétrique, 438 tweets non négatifs et 425 tweets négatifs sont bien classés, avec 175 faux positifs et 162 faux négatifs pour cette classe. Cette symétrie est cohérente avec la construction du score ($P(\text{positif}) - P(\text{négatif})$) sur un dataset équilibré.

3. Précision, Rappel, F1-score

Classe	Précision	Rappel	F1-score
Positif	0.730	0.715	0.722
Négatif	0.708	0.724	0.716

Le modèle atteint une exactitude globale d'environ 72 %, avec des scores très proches entre les deux classes ($F1 \approx 0.72$ pour le positif, 0.72 pour le négatif). L'absence d'écart marqué entre précision et rappel sur chaque classe indique un modèle équilibré, ni trop conservateur ni trop permissif dans ses prédictions positives.

4. Analyse des Performances et Biais

Forces : le modèle généralise correctement sur un vocabulaire varié grâce au TF-IDF bigrammes, et les performances sont stables entre les deux classes (pas de biais structurel positif/négatif détecté dans les matrices de confusion).

Faiblesses observées : environ 28 % d'erreurs, concentrées sur des tweets ambigus, courts ou sarcastiques, difficiles à distinguer avec un simple sac de mots TF-IDF (le modèle ne capture pas le contexte ni la négation complexe, par exemple "pas mal du tout").

Biais liés au dataset : les tweets utilisés proviennent d'un corpus (Sentiment140) annoté automatiquement par émoticônes puis traduit de l'anglais vers le français, ce qui introduit du bruit : certaines traductions sont maladroites, et l'annotation par émoticône ne capture pas toujours le sarcasme ou l'ironie. Les tweets datent également de 2009, ce qui peut limiter la représentativité du vocabulaire actuel sur X.

5. Recommandations

- Enrichir le dataset avec des tweets français annotés manuellement (par exemple le corpus Canéphore) pour réduire le bruit d'annotation.
- Tester des modèles capturant mieux le contexte (embeddings de mots, modèles transformer type CamemBERT) pour améliorer la prise en compte de la négation et du sarcasme.
- Ajouter une classe neutre pour les tweets sans sentiment marqué, plutôt que de forcer une classification binaire.
- Mettre en place un suivi des performances à chaque réentraînement hebdomadaire pour détecter une éventuelle dérive du modèle (data drift).